Enginyeria de Telecomunicació (GRETST)

Probabilitat i Estadística

2 de juny de 2023 | **Examen final** | **Temps: 3h**

Notes finals provisionals: 9 de juny | **Revisió d'examen:** 12 de juny, de 10:30 a 13:00

1. Els conjunts de símbols d'entrada i de sortida d'un canal de comunicació són $\{a, b\}$ i $\{0, 1\}$, respectivament. Sabem que $\mathbb{P}(\text{rebre } 0 \,|\, \text{s'envia } a) = \mathbb{P}(\text{rebre } 1 \,|\, \text{s'envia } b) = 4/5$. Sabem també que la probabilitat de tenir a l'entrada del canal el símbol a val el doble que la probabilitat de tenir-hi b.

Per tal de transmetre un determinat símbol $x \in \{a, b\}$, aquest s'envia (de forma independent) n vegades consecutives i s'observa la seqüència binària B rebuda a la sortida del canal.

(a) Calculeu la probabilitat que s'hagi transmès el símbol a si B conté exactament k uns.

(b) Calculeu el nombre esperat d'uns que conté la seqüència B.

(c) En aquest apartat, $n = 3$. Per tal de decidir quin símbol s'ha transmès s'aplica la regla de decisió següent: si B conté més zeros que uns es decideix que el símbol transmès és a; altrament, es decideix b. Calculeu la probabilitat de decidir erròniament. **(2,5 punts)**

Resolució

Noteu que $\mathbb{P}(\text{rebre } 1 \,|\, \text{s'envia } a) = 1 - \mathbb{P}(\text{rebre } 0 \,|\, \text{s'envia } a) = 1/5$. Anàlogament, $\mathbb{P}(\text{rebre } 0 \,|\, \text{s'envia } b) = 1 - \mathbb{P}(\text{rebre } 1 \,|\, \text{s'envia } b) = 1/5$. Noteu també que $\mathbb{P}(a) = 2\,\mathbb{P}(b)$ i, per tant, $\mathbb{P}(a) = 2/3$ i $\mathbb{P}(b) = 1/3$ (ja que $\mathbb{P}(a) + \mathbb{P}(b) = 1$).

(a) Diem X a la variable aleatòria que compta el nombre d'uns en la seqüència B rebuda. Noteu que X condicionada per "es transmet el símbol a" és binomial de paràmetres n i $1/5$. Anàlogament, X condicionada per "es transmet el símbol b" és binomial de paràmetres n i $4/5$. Per tant,

$$\begin{aligned}\mathbb{P}(X = k) &= \mathbb{P}(X = k \,|\, a)\,\mathbb{P}(a) + \mathbb{P}(X = k \,|\, b)\,\mathbb{P}(b) \\ &= \frac{2}{3}\binom{n}{k}\left(\frac{1}{5}\right)^k\left(\frac{4}{5}\right)^{n-k} + \frac{1}{3}\binom{n}{k}\left(\frac{4}{5}\right)^k\left(\frac{1}{5}\right)^{n-k}, \quad k = 0, 1, \ldots, n \qquad (1)\end{aligned}$$

Ara, aplicant la fórmula de Bayes:

$$\mathbb{P}(a \,|\, X = k) = \frac{\mathbb{P}(X = k \,|\, a)\,\mathbb{P}(a)}{\mathbb{P}(X = k)} = \frac{2 \cdot 4^{n-k}}{2 \cdot 4^{n-k} + 4^k}, \quad k = 0, 1, \ldots, n.$$

(b) Condicionant pel símbol transmès, tenim

$$\mathbb{E}[X] = \mathbb{E}[X \,|\, a]\,\mathbb{P}(a) + \mathbb{E}[X \,|\, b]\,\mathbb{P}(b) = \frac{n}{5} \cdot \frac{2}{3} + \frac{4n}{5} \cdot \frac{1}{3} = \frac{2n}{5}.$$

Observació: La probabilitat de rebre 1 en cada enviament del símbol que s'està transmetent val

$$\mathbb{P}(\text{rebre } 1) = \frac{1}{5} \cdot \frac{2}{3} + \frac{4}{5} \cdot \frac{1}{3} = \frac{2}{5}.$$

Encara que $\mathbb{E}[X] = 2n/5$, la variable X *no és* binomial de paràmetres n i $2/5$. En efecte, si ho fos, i, per exemple, $n = 3$, tindríem $\mathbb{P}(X = 0) = (3/5)^3 = 27/125$. En canvi, per a $n = 3$ i $k = 0$, l'expressió (1) dóna $\mathbb{P}(X = 0) = (2/3)(4/5)^3 + (1/3)(1/5)^3 = 43/125$. (El que passa és que X no és binomial perquè els bits de la seqüència B rebuda no són independents.)

(c) Si es transmet a es decidirà erròniament si el nombre d'uns que conté la seqüència B és dos o tres. En canvi, si es transmet b tindrem error quan el nombre d'uns a B és zero o un.

Condicionant pels símbols d'entrada, podem calcular la probabilitat $\mathbb{P}(\epsilon)$ de decidir erròniament com:

$$\begin{aligned}\mathbb{P}(\epsilon) &= \mathbb{P}(\epsilon \,|\, a)\,\mathbb{P}(a) + \mathbb{P}(\epsilon \,|\, b)\,\mathbb{P}(b) = \mathbb{P}(X \geq 2 \,|\, a)\,\mathbb{P}(a) + \mathbb{P}(X \leq 1 \,|\, b)\,\mathbb{P}(b) \\ &= \frac{2}{3}\left(\binom{3}{2}\left(\frac{1}{5}\right)^2\left(\frac{4}{5}\right) + \binom{3}{3}\left(\frac{1}{5}\right)^3\right) + \frac{1}{3}\left(\binom{3}{0}\left(\frac{1}{5}\right)^3 + \binom{3}{1}\left(\frac{4}{5}\right)\left(\frac{1}{5}\right)^2\right) = \frac{13}{125}.\end{aligned}$$

2. La funció de densitat de probabilitat d'una variable aleatòria contínua X val $f_X(x) = 0$ si $x < 0$, $f_X(x) = x/a^2$ si $0 \le x \le a$, i $f_X(x) = a^2/x^3$ si $x > a$, on $a > 0$ és un paràmetre.

(a) Determineu la funció de distribució de probabilitat de X i calculeu $\mathbb{E}(X)$. Què podeu dir sobre la variància de X? Obteniu la funció de densitat condicionada $f_X(x \,|\, X{>}a)$.

(b) Considereu la variable $U = g(X)$, on $g(x) = 1$ si $|x - a| \le a/2$ i $g(x) = 0$ altrament. Calculeu $\mathbb{P}(U = 0)$.

(c) Determineu la funció de densitat de probabilitat de la variable $Y = +\sqrt{X}$.

(d) A partir d'una mostra $Y_1, \ldots, Y_n$ de la variable Y, trobeu l'estimador pel mètode dels moments del paràmetre a. **(3 punts)**

Resolució

(a) La funció de distribució de probabilitat de X és $\mathsf{F}_X(x) = \int_{-\infty}^{x} f_X(u)\,\mathrm{d}u$.

- Si $x \le 0$, clarament $\mathsf{F}_X(x) = 0$.
- Si $0 < x \le a$, aleshores $\mathsf{F}_X(x) = \displaystyle\int_0^x \frac{u}{a^2}\,\mathrm{d}u = \frac{x^2}{2a^2}$.
- Si $x > a$, $\mathsf{F}_X(x) = \mathsf{F}_X(a) + \displaystyle\int_a^x \frac{a^2}{u^3}\,\mathrm{d}u = \frac{1}{2} + \left(\frac{1}{2} - \frac{a^2}{2x^2}\right) = 1 - \frac{a^2}{2x^2}$.

L'esperança de X val

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x)\,\mathrm{d}x = \int_0^a \frac{x^2}{a^2}\,\mathrm{d}x + \int_a^\infty \frac{a^2}{x^2}\,\mathrm{d}x = \frac{a}{3} + a = \frac{4a}{3}.$$

La variància de X no existeix perquè no existeix $\mathbb{E}[X^2] = \int_{\mathbb{R}} x^2 f_X(x)\,\mathrm{d}x$, ja que la integral $\int_a^{+\infty} a^2/x\,\mathrm{d}x$ és divergent.
A l'últim,

$$f_X(x \,|\, X{>}a) = \frac{f_X(x)}{\mathbb{P}(X{>}a)} = \frac{f_X(x)}{1 - \mathsf{F}_X(a)} = \frac{2a^2}{x^3} \quad \text{per a } x > a\,.$$

(b) $U = 0$ sii $|X - a| > a/2$ sii $X < a/2$ o $X > 3a/2$. Per tant

$$\mathbb{P}(U{=}0) = \mathbb{P}(X{<}a/2) + \mathbb{P}(X{>}3a/2) = \mathsf{F}_X(a/2) + 1 - \mathsf{F}_X(3a/2) = 1/8 + 2/9 = 25/72\,.$$

(c) Si $y > 0$, l'equació $y = h(x) = +\sqrt{x}$ té solució única $x = y^2$. Per tant, aplicant el teorema del canvi de variable, tenim

$$f_Y(y) = \left.\frac{f_X(x)}{|h'(x)|}\right|_{x=y^2} = 2y\, f_X(y^2) = \begin{cases} \dfrac{2y^3}{a^2}, & 0 < y < \sqrt{a} \\[2ex] \dfrac{2a^2}{y^5}, & y > \sqrt{a} \end{cases}$$

(d) A fi de trobar l'estimador del paràmetre a a partir d'una mostra $Y_1, \ldots, Y_n$, hem de conèixer el primer moment $m_1 = \mathbb{E}[Y]$. Usant, per exemple, el teorema de l'esperança,

$$m_1 = \mathbb{E}[Y] = \int_{\mathbb{R}} h(x) f_X(x)\,\mathrm{d}x = \frac{1}{a^2}\int_0^a x^{3/2}\,\mathrm{d}x + a^2 \int_a^{+\infty} x^{-5/2}\,\mathrm{d}x = \frac{2\sqrt{a}}{5} + \frac{2\sqrt{a}}{3} = \frac{16\sqrt{a}}{15}\,.$$

D'aquí obtenim la relació $a = \left(\frac{15}{16}\, m_1\right)^2$.
Reemplaçant-hi a per l'estimador buscat $\widehat{a}$, i m_1 pel primer moment mostral, $\overline{Y}_n$, obtenim

$$\widehat{a} = \left(\frac{15}{16}\,\overline{Y}_n\right)^2.$$

3. Siguin X, S variables aleatòries independents tals que $X \sim \mathsf{N}(0,1)$ i S és discreta i pren els valors ± 1 de manera equiprobable. Sigui $Y = SX$.

(a) Proveu que $Y \sim \mathsf{N}(0,1)$.
(Indicació: calculeu $\mathsf{F}_Y(y)$ tot usant la fórmula de la probabilitat total condicionant pels valors $S = \pm 1$.)

(b) Demostreu que $\mathbb{P}(X{+}Y{=}0) = 1/2$. Deduïu-ne que (X, Y) *no* és una variable bidimensional contínua, i que $X + Y$ *no* és una variable aleatòria gaussiana.

(c) Proveu que X, Y són variables gaussianes incorrelades però *no* són independents. **(2,5 punts)**

Resolució

(a) Provarem que $Y \sim \mathsf{N}(0,1)$ demostrant que té la mateixa funció de distribució que X. Calculem:

$$\begin{aligned}\mathsf{F}_Y(y) = \mathbb{P}(Y \le y) &= \mathbb{P}(Y{\le}y \,|\, S{=}{-}1)\,\mathbb{P}(S{=}{-}1) + \mathbb{P}(Y{\le}y \,|\, S{=}1)\,\mathbb{P}(S{=}1)\\ &= \mathbb{P}(-X{\le}y \,|\, S{=}-1)\,\mathbb{P}(S{=}{-}1) + \mathbb{P}(X{\le}y \,|\, S{=}1)\,\mathbb{P}(S{=}1)\\ &= \big(\mathbb{P}(X \ge -y) + \mathbb{P}(X \le y)\big)\,\frac{1}{2} = \mathbb{P}(X \le y) = \mathsf{F}_X(y),\end{aligned}$$

on hem usat la fórmula de la probabilitat total condicionant per $S = \pm 1$, que X i S són variables independents (per tant $\mathbb{P}(X{\in}A \,|\, S{\in}B) = \mathbb{P}(X{\in}A)$), i que, per la simetria de la densitat normal estàndard, $\mathbb{P}(X{\ge}{-}y) = \mathbb{P}(X{\le}y)$.

(b) Com que $Y = SX$, si $S = -1$, llavors $X + Y = 0$, mentre que si $S = 1$, aleshores $X + Y = 2X$. Per tant,

$$\begin{aligned}\mathbb{P}(X{+}Y{=}0) &= \mathbb{P}(X{+}Y{=}0 \,|\, S{=}{-}1)\,\mathbb{P}(S{=}{-}1) + \mathbb{P}(X{+}Y{=}0 \,|\, S{=}1)\,\mathbb{P}(S{=}1)\\ &= \mathbb{P}(0{=}0 \,|\, S{=}{-}1)\,\mathbb{P}(S{=}{-}1) + \mathbb{P}(2X{=}0 \,|\, S{=}1)\,\mathbb{P}(S{=}1) = 1 \cdot \frac{1}{2} + 0 \cdot \frac{1}{2} = \frac{1}{2},\end{aligned}$$

on hem tornat a usar la fórmula de la probabilitat total, hem tingut en compte que X i S són independents, i que $\mathbb{P}(X{=}0) = 0$ per ser X una variable contínua.
(*Alternativament*: $X{+}Y = X(1{+}S)$, de manera que $X{+}Y = 0 \iff (X = 0$ o $S = -1)$. Per tant $\mathbb{P}(X{+}Y{=}0) = \mathbb{P}(X{=}0) + \mathbb{P}(S{=}{-}1) - \mathbb{P}(X{=}0$ i $S{=}{-}1) = 0 + 1/2 - 0$.)
La variable bidimensional (X, Y) no pot ser contínua. En efecte, si $B = \{(x, y) \in \mathbb{R}^2 \mid x{+}y = 0\}$, llavors $\mathbb{P}(X{+}Y{=}0) = \mathbb{P}((X, Y) \in B)$; com que el conjunt B té àrea nul·la, si (X, Y) admetés una funció de densitat la seva integral sobre B valdria zero.
Pel mateix motiu, si $Z = X{+}Y$ fos una variable gaussiana (i per tant contínua) també hauríem de tenir $\mathbb{P}(Z{=}0) = 0$.

(c) Calculem la covariància de X i Y:

$$\mathrm{Cov}[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\,\mathbb{E}[Y] = \mathbb{E}[SX^2] = \mathbb{E}[S]\,\mathbb{E}[X^2] = 0\,,$$

on hem usat $\mathbb{E}[X] = \mathbb{E}[Y] = 0$, que S i X són independents, i $\mathbb{E}[S] = 0$. Així, les variables gaussianes X i Y són incorrelades.
Tanmateix, X i Y no poden ser independents, ja que, si ho fossin, $X + Y$ seria gaussiana i ja hem vist que no ho és.

Observeu que els resultats d'aquest exercici no contradiuen la proposició estudiada en el curs: "si dues variables aleatòries *conjuntament gaussianes* són incorrelades, aleshores són independents", ja que les variables X i Y del problema, tot i ser gaussianes, no ho són conjuntament.

4. Una mostra de les edats de 100 defuncions produïdes en un cert territori ha donat una mitjana de 71.8 anys. Assumim que la desviació estàndard val $\sigma = 8.9$ anys.

(a) Determineu un interval del 95% de confiança per a l'edat de defunció mitjana.

(b) Podríem afirmar que l'edat de defunció mitjana és de més de 70 anys? Utilitzeu un test d'hipòtesi amb nivell de significació del 5%, així com el valor P. A quina conclusió arribaríem si el nivell de significació fos de l'1%?

(c) En lloc d'assumir que $\sigma = 8.9$, ara suposem que el valor 8.9 correspon a la desviació calculada a partir de la mostra. Com canviarien els càlculs de l'apartat (a)? Per què l'interval que s'obtindria és molt similar, però una mica més ample? **(2 punts)**

Resolució

Com que la mida de la mostra és gran, suposem que la població és gaussiana $\mathsf{N}(\mu, \sigma{=}8.9)$.

(a) Si X és la variable poblacional, aleshores $Z = (\overline{X}_n - \mu)/(\sigma/\sqrt{n}) \sim \mathsf{N}(0,1)$, i l'interval de confiança de nivell c és de la forma $\overline{X}_n \pm z_\circ \sigma/\sqrt{n}$, on $z_\circ = \mathsf{F}_Z^{-1}((1+c)/2)$. En el nostre cas, $\overline{x} = 71.8$, $\sigma = 8.9$, $n = 100$, i $z_\circ = \mathsf{F}_Z^{-1}(0.975) = 1.960$. Per tant, l'interval determinat a partir de la mostra és

$$\left(71.8 - 1.960\,\frac{8.9}{10}\ ,\ 71.8 - 1.960\,\frac{8.9}{10}\right) = (70.056\,,\,73.544)$$

(b) Si $\mu_0 = 70$, confrontem la hipòtesi H_0: $\mu = \mu_0$ amb H_1: $\mu > \mu_0$. L'estadístic de test és la normal estàndard $Z = (\overline{X} - \mu_0)/(\sigma/\sqrt{n})$, essent $n = 100$. Amb les dades donades el valor de Z és $z = 2.022$.
Amb un nivell de significació $\alpha = 0.05$ la regió crítica és $Z > \mathsf{Q}_Z(0.95) = 1.645$, de manera que rebutgem la hipòtesi i concloem que $\mu > 70$.
El valor P del test és $\mathbb{P}(Z{>}z) = 1 - \mathsf{F}_Z(z) = 0.0216$, que també suggereix rebutjar la hipòtesi nul·la. (Del formulari veiem que si $z > 1.960$, aleshores $\mathsf{F}_Z(z) > 0.975$, i, per tant, el valor P del test és menor que 0.025.)
Amb un nivell de significació $\alpha = 0.01$ la regió crítica és $Z > \mathsf{Q}_Z(0.99) = 2.326$, de manera que ara no rebutjaríem la hipòtesi nul·la.

(c) Si el valor 8.9 correspon a la desviació calculada a partir de la mostra, l'interval de confiança per l'esperança poblacional el determinaríem usant l'estadístic $T = (\overline{X}_n - \mu)/(\hat{\sigma}_n/\sqrt{n}) \sim \mathsf{t}_{n-1}$. Com que $n = 100$, la distribució t de Student amb 99 graus de llibertat és molt aproximadament la distribució normal estàndard, amb la qual cosa l'interval determinat a partir de la mostra serà aproximadament el mateix. De totes maneres, el valor crític $t_\circ = \mathsf{F}_{t_{n-1}}^{-1}((1+c)/2)$ serà una mica més gran que $z_\circ = \mathsf{F}_Z^{-1}((1+c)/2)$, i obtindrem un interval una mica més ample.